## **Objectifs**

Construire un algorithme qui, à partir des caractéristiques géométriques d'un billet, serait capable de définir si ce dernier est un vrai ou un faux billet.

### **Sommaire**

- Analyse des billets
- Régression linéaire
- K-means
- Knn
- Régression logistique
- Conclusion





### **Analyse:**

### Présentation des données:

|   | is_genuine | diagonal | height_left | height_right | margin_low | margin_up | length |
|---|------------|----------|-------------|--------------|------------|-----------|--------|
| 0 | True       | 171.81   | 104.86      | 104.95       | 4.52       | 2.89      | 112.83 |
| 1 | True       | 171.46   | 103.36      | 103.66       | 3.77       | 2.99      | 113.09 |
| 2 | True       | 172.69   | 104.48      | 103.50       | 4.40       | 2.94      | 113.16 |
| 3 | True       | 171.36   | 103.91      | 103.94       | 3.62       | 3.01      | 113.51 |
| 4 | True       | 171.73   | 104.28      | 103.46       | 4.04       | 3.48      | 112.54 |

#### **Valeurs manquantes:**

Des valeurs manquantes dans la colonne margin\_low


Vrai billet : 29 valeurs manquantes

Faux billet: 8 valeurs manquantes

Total billet: 37 valeurs manquantes



# Analyse des billets :





### **Combler les valeurs manquantes :**

### **Régression linéaire:**

| Dep. Variable:     | marg       | in_low  | R-squared:     |       | 0.61      | 7    |
|--------------------|------------|---------|----------------|-------|-----------|------|
| Model:             |            | OLS     | Adj. R-squared |       | 0.61      |      |
| Method:            | Least S    | quares  | F-statistic:   |       | 390.7     | 7    |
| Date:              | Sun, 27 No | v 2022  | Prob (F-statis | tic): | 4.75e-299 | 9    |
| Time:              | 18         | :17:12  | Log-Likelihood |       | -774.1    |      |
| No. Observations:  |            | 1463    | AIC:           |       | 1562      |      |
| Df Residuals:      |            | 1456    | BIC:           |       | 1599      |      |
| Df Model:          |            |         |                |       |           |      |
| Covariance Type:   | non        | robust  |                |       |           |      |
|                    | coef       | std eri | t              | P> t  | [0.025    | 0.97 |
| Intercept          | 2.8668     | 8.31    | 0.345          | 0.730 | -13.445   | 19.1 |
| is_genuine[T.True] | -1.1406    | 0.050   | -23.028        | 0.000 | -1.238    | -1.0 |
| diagonal           | -0.0130    | 0.03    | 6 -0.364       | 0.716 | -0.083    | 0.0  |
| height_left        | 0.0283     | 0.039   | 9 0.727        | 0.468 | -0.048    | 0.1  |
| height_right       | 0.0267     | 0.038   | 0.701          | 0.484 | -0.048    | 0.1  |
| margin_up          | -0.2128    | 0.059   | 9 -3.621       | 0.000 | -0.328    | -0.0 |
| length             |            |         | 3 -0.166<br>   |       | -0.050    |      |
| Omnibus:           |            | 21.975  |                |       | 2.038     |      |
| Prob(Omnibus):     |            | 0.000   | Jarque-Bera (J | B):   | 37.99     | 3    |
| Skew:              |            | 0.061   | Prob(JB):      |       | 5.62e-09  | 7    |
| Kurtosis:          |            | 3.780   | Cond. No.      |       | 1.95e+0   |      |

R<sup>2</sup>: 0,617

Test de colinéarité :

[1.5938854494007755, 1.5938854494007748]


Test autocorrélation Durbin Watson:

2.0410819121411503

MSE: 0,16317666353515042

Contenant tout mes nul : data\_nul

Sans aucun nul : data\_clean



#### **Test Shapiro:**

ShapiroResult(statistic=0.9936248064041138, pvalue=6.20942773821298e-06)

#### Test d'homoscédasticité :

```
[('Bresuch-Pagan test', 163.45772873027045),
('p-value', 3.2033559115836335e-36),
('f-value', 91.82013129631463),
('f p-value', 2.745628359363973e-38)]
```




#### **Dataframe Final:**

| Data | columns (tota | l 7 columns):  |         |
|------|---------------|----------------|---------|
| #    | Column        | Non-Null Count | Dtype   |
|      |               |                |         |
| 0    | is_genuine    | 1500 non-null  | bool    |
| 1    | diagonal      | 1500 non-null  | float64 |
| 2    | height_left   | 1500 non-null  | float64 |
| 3    | height_right  | 1500 non-null  | float64 |
| 4    | margin_up     | 1500 non-null  | float64 |
| 5    | length        | 1500 non-null  | float64 |
| 6    | margin_low    | 1500 non-null  | float64 |

### **Données prédites :**










## Knn:


## **Données prédite :**



## 99% de réussite pour le modèle knn

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
|              |           |        |          |         |
| 0            | 0.99      | 0.99   | 0.99     | 105     |
| 1            | 0.99      | 0.99   | 0.99     | 195     |
|              |           |        |          |         |
| accuracy     |           |        | 0.99     | 300     |
| macro avg    | 0.99      | 0.99   | 0.99     | 300     |
| weighted avg | 0.99      | 0.99   | 0.99     | 300     |
|              |           |        |          |         |

## K-nn roc:



98% score AUC


0.989700980148266





## **Régression logistique :**


## **Données prédite :**



## 99% de réussite pour la Régression logistique

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| False        | 1.00      | 0.98   | 0.99     | 86      |
| True         | 0.99      | 1.00   | 1.00     | 207     |
|              |           |        |          |         |
| accuracy     |           |        | 0.99     | 293     |
| macro avg    | 1.00      | 0.99   | 0.99     | 293     |
| weighted avg | 0.99      | 0.99   | 0.99     | 293     |
|              |           |        |          |         |

## Régression logistique roc:



99% score AUC

0.9994515357000399



## **Conclusion**

Des 3 algorithmes utiliser le KNN et la régression logistique sont ceux avec les meilleurs résultat.

## **KNN**

- Lent quand jeu de données conséquent
- N'est pas demander dans le projet

## Régression logistique

- Peut être utiliser sur un jeu de données conséquent
- Demander dans le projet